

الأوراق العلمية لمشروع CS-681

توليد تقارير نصية وصوتية من صور قاع العين لاعتلال الشبكية السكري

الشرط: مراجعة 10 أوراق على الأقل من آخر 3 سنوات (2023 وما بعد). كل الأوراق العشر التالية تحقق الشرط ✓

تنبيهات قبل الكتابة

- ورقة FFA-GPT: المؤلف الأول هو X. Chen، مو Y. Zhang مثل ما كان مكتوب في البروبوزال، فلانزم تصحيحه.
- ورقة Gated Contextual Transformer: المؤلفين هم N. S. Shaik وزملاؤه، مو S. Li، وتأكدوا من رقم المجلد والصفحات من موقع المجلة.
- مرجع Huang (رقم 6 في البروبوزال) طلع رسالة دكتوراه منشورة على arXiv، والأفضل ما نحسبه من العشر.
- مرجع Liu (رقم 7 في البروبوزال) ناقص بيانات النشر، فما حسبناه.
- SpeechT5 (2022) و Gulshan (2016) و Kermayn (2018) و Wang (2021) تبقى كمراجع، بس ما تنحسب من العشر.
- Whisper ورقة جديدة لازم تنضاف للمراجع لأنها مستخدمة في تقييم الصوت.

الورقة 1: LLaVA: Visual Instruction Tuning (2023)

H. Liu, C. Li, Q. Wu, and Y. J. Lee, "Visual instruction tuning," in Proc. Advances in Neural Information Processing Systems (NeurIPS), 2023.

الفكرة: ربطوا مُشغّر صور جاهز (CLIP) بنموذج لغوي كبير عن طريق طبقة إسقاط بسيطة، ودربوه على بيانات تعليمات (صورة + سؤال + جواب) ولدها GPT-4. النتيجة نموذج يقدر يتحاور عن الصور ويجاوب أسئلة مفتوحة عنها.

العيوب: نموذج عام مو طي، فما يفهم الصور الطبية بدقة. ينتج هلوسة (يوصف أشياء مو موجودة في الصورة). وجزء من تقييمه يعتمد على GPT-4 كحكم، وهذا تقييم غير موضوعي تماماً.

وش تفيدنا: هو الأساس اللي بُنيت عليه فكرة نماذج الرؤية واللغة الحديثة (ومنها LLaVA-Med). نستخدمه نشرح فيه كيف تشتغل هذي النماذج بشكل عام، وليش النماذج العامة ما تكفي للمجال الطبي، وهذا يمرر اختيارنا لـ MedGemma.

مكانها في الورقة: Related Work: قسم نماذج الرؤية واللغة العامة.

الورقة 2: BLIP-2 (2023)

J. Li, D. Li, S. Savarese, and S. Hoi, "BLIP-2: Bootstrapping language-image pre-training with frozen image encoders and large language models," in Proc. Int. Conf. Machine Learning (ICML), 2023.

الفكرة: بدل ما يدربون نموذج كامل من الصفر، جمدوا مُشغّر صور جاهز ونموذج لغوي جاهز، وربطوهم بوحدة صغيرة اسمها Q-Former. هذا خلى التدريب أرخص بكثير مع أداء قوي في وصف الصور والإجابة عن أسئلة حولها.

العيوب: لأن المُشغّرات مجمّدة، قدرته على التكيف مع مجال مختلف جداً (مثل صور قاع العين) محدودة بدون تدريب إضافي. وتدريب على صور عامة من الإنترنت.

وش تفيدنا: طريقة BLIP هي اللي استخدمتها ورقة FFA-GPT لتوليد تقارير العين، فهو حلقة وصل بين النماذج العامة وتطبيقات طب العيون. ويوضح مفهوم استخدام نماذج جاهزة بدون تدريب كامل، وهو نفس أسلوبنا (inference فقط).

مكانها في الورقة: Related Work: قسم نماذج الرؤية واللغة العامة.

الورقة 3: InstructBLIP (2023)

W. Dai, J. Li, D. Li, A. M. H. Tiong, J. Zhao, W. Wang, B. Li, P. Fung, and S. Hoi, "InstructBLIP: Towards general-purpose vision-language models with instruction tuning," in Proc. NeurIPS, 2023.

الفكرة: طوّروا BLIP-2 بتدريبه على مجموعة كبيرة ومتنوعة من التعليمات، وخلوا الـ Q-Former ينتبه للتعليمات نفسها وهو يستخرج ميزات الصورة. فصار النموذج يتبع تعليمات المستخدم بشكل أفضل ويتعمم على مهام ما شافها.

العيوب: ما زال نموذج عام مو طي. وأداؤه يعتمد كثير على صياغة التعليم، ويمكن إنتاج هلوسة.

وش تفيدنا: يثبت إن صياغة التعليم (البرومبت) تؤثر بشكل كبير على جودة المخرجات، وهذا بالضبط اللي نقيسه في مقارنتنا بين Structured Template و Zero-shot.

مكانها في الورقة: Related Work + Methodology (عند تبرير مقارنة أساليب البرومبت).

الورقة 4: LLaVA-Med (2023)

C. Li, C. Wong, S. Zhang, N. Usuyama, H. Liu, J. Yang, T. Naumann, H. Poon, and J. Gao, "LLaVA-Med: Training a large language-and-vision assistant for biomedicine in one day," in Proc. NeurIPS Datasets and Benchmarks Track, 2023.

الفكرة: أخذوا صور طبية مع تعليقاتها من مقالات PubMed Central، وخلوا GPT-4 يحولها لبيانات تعليمات، ثم دربو LLaVA عليها بطريقة curriculum learning. التدريب أخذ أقل من 15 ساعة، والنموذج تفوق على النماذج السابقة في بعض مقاييس الأسئلة والأجوبة الطبية.

العيوب: تدرب على تعليقات صور من مقالات علمية، مو تقارير سريرية حقيقية. تقييم المحادثة اعتمد على GPT-4 كحكم. وما ركز على طب العيون تحديداً.

وش تفيدنا: من أوائل نماذج الرؤية واللغة الطبية، فهو يمثل المرحلة اللي قبل MedGemma. نستخدمه نوضح التطور من النماذج العامة للطبية، والفرق بين النماذج الطبية العامة والمتخصصة.

مكانها في الورقة: Related Work: قسم نماذج الرؤية واللغة الطبية.

الورقة 5: FFA-GPT (2024)

X. Chen, W. Zhang, P. Xu, Z. Zhao, Y. Zheng, D. Shi, and M. He, "FFA-GPT: An automated pipeline for fundus fluorescein angiography interpretation and question-answer," npj Digital Medicine, vol. 7, art. no. 111, 2024, doi: 10.1038/s41746-024-01101-z.

الفكرة: نظام من مرحلتين: الأولى تستخدم BLIP لتوليد تقرير من صور تصوير الأوعية بالصبغة (FFA)، والثانية تستخدم Llama 2 للإجابة عن أسئلة المريض أو الطبيب عن التقرير. تدرب على أكثر من 654 ألف صورة و9392 تقرير، وتقيم آلياً وبشرياً من 3 أطباء عيون.

العيوب: يشتغل على صور FFA (تحتاج حقن صبغة) مو صور قاع العين العادية. البيانات من مركز واحد في الصين. ويحتاج تدريب على بيانات ضخمة غير متاحة للعامة.

وش تفيدنا: أقرب ورقة لفكرة مشروعنا: توليد تقرير نصي من صور العين + تقييمه آلياً وبشرياً. نستفيد من طريقة تقييمهم (مقاييس آلية + تقييم أطباء) لتبرير تقييمنا المزدوج.

مكانها في الورقة: Related Work: قسم توليد التقارير الطبية لصور العين.

الورقة 6: Gated Contextual Transformer (2024)

N. S. Shaik, T. K. Cherukuri, and D. H. Ye, "Gated contextual transformer network for multi-modal retinal image clinical description generation," Image and Vision Computing, 2024.

الفكرة: نموذج Transformer يولد وصف سريري لصور الشبكية، ويدمج ميزات الصورة مع كلمات مفتاحية تشخيصية عن طريق آلية بوابات (gating) تتحكم في كمية المعلومات من كل مصدر.

العيوب: يحتاج كلمات مفتاحية تشخيصية كمدخل إضافي، وهذي مو متوفرة دائماً في الواقع. وتقييمه يعتمد على مقاييس تشابه نصي مثل BLEU، وهذي ما تقيس الصحة الطبية للوصف.

وش تفيدنا: يمثل الأسلوب التقليدي (نموذج مدرب خصباً لمهمة واحدة)، ونقارنه بأسلوبنا (نموذج عام جاهز مع برومبت بدون تدريب). وعيب BLEU يبرر لبش احنا نقيس الدقة الطبية والاتساق الداخلي بدل التشابه النصي.

مكانها في الورقة: Related Work: قسم توليد التقارير الطبية لصور العين.

الورقة 7: MedGemma Technical Report (2025)

A. Sellergren et al., "MedGemma technical report," arXiv preprint arXiv:2507.05201, 2025.

الفكرة: مجموعة نماذج طبية مفتوحة من Google مبنية على Gemma 3. منها نسخة 4B متعددة الوسائط تفهم الصور الطبية (أشعة، جلد، أنسجة، عيون) وتولد نص. مصممة كنقطة بداية للمطورين في التطبيقات الطبية.

العيوب: تقرير تقني من نفس الشركة المطورة، فالتقييم مو مستقل. التحقق في طب العيون تحديداً محدود. وصور قاع العين دخلت في تدريبه، فممكن يكون شاف صور مشابهة لبياناتنا.

وش تفيدنا: هو النموذج الأساسي في مشروعنا، فلازم نوصفه بالتفصيل. ومعلومة إن صور العين دخلت في تدريبه مهمة جداً لقسم Limitations (احتمال تسرب البيانات).

مكانها في الورقة: Methodology (وصف النموذج) + Limitations.

الورقة 8: EyeFM (2025)

Y. Wu et al., "An eyecare foundation model for clinical assistance: A randomized controlled trial," *Nature Medicine*, vol. 31, pp. 3404-3413, 2025, doi: 10.1038/s41591-025-03900-7.

الفكرة: نموذج رؤية ولغة لطب العيون تدريب مسبقاً على 14.5 مليون صورة عين من خمس طرق تصوير مع نصوص سريرية. اختبروه في تجربة سريرية عشوائية مع 668 مريض و16 طبيب عيون، والأطباء اللي استخدموه حققوا تشخيص صحيح أعلى (92.2%) مقابل (75.4%) وتقارير أكثر توحيداً.

العيوب: التجربة السريرية في مركز واحد في الصين، وأغلب المشاركين ذكور. البيانات الضخمة اللي تدريب عليها مو متاحة للعامه، فصعب تكرار النتائج.

وش تفيدنا: أقوى دليل إن نماذج الرؤية واللغة في طب العيون تفيد الأطباء فعلياً، فهو ممتاز لدافع المشروع في المقدمة. وتحسن توحيد التقارير يدعم فكرة البرومبت المنظم عندنا.

مكانها في الورقة: Introduction (الدافع) + Related Work.

الورقة 9: Barakat & Lotter: Simulating Clinical AI Assistance (2025)

N. Barakat and W. Lotter, "Simulating clinical AI assistance using multimodal LLMs: A case study in diabetic retinopathy," *arXiv preprint arXiv:2509.13234*, 2025.

الفكرة: قارنوا MedGemma مع GPT-4o في كشف اعتلال الشبكية السكري على IDriD و MedGemma-2. كان أفضل (AUROC وصل 0.95)، و GPT-4o لما أخذ وصف MedGemma النصي وصل 0.96 حتى بدون ما يشوف الصورة.

العيوب: بيانات صغيرة (103 و175 صورة). ركزوا على قرار الإحالة الثنائي ودرجة شدة عامة، مو التصنيف الكامل للدرجات الخمس. ما قارنوا أساليب برومبت، وما قاسوا هلوسة الأوصاف. وهي preprint (ما تمت مراجعتها بالكامل).

وش تفيدنا: أقرب ورقة لمشروعنا: نفس النموذج ونفس المرض ونفس أسلوب العينة المتوازنة. تثبت إن الوصف النصي أفيد من التصنيف الثنائي. والأشياء اللي ما سووها (مقارنة البرومبت، الاتساق الداخلي، الصوت) هي مساهمتنا الإضافية.

مكانها في الورقة: Related Work + Discussion (مقارنة نتائجنا بنتائجهم).

الورقة 10: Whisper (2023)

A. Radford, J. W. Kim, T. Xu, G. Brockman, C. McLeavey, and I. Sutskever, "Robust speech recognition via large-scale weak supervision," in *Proc. ICML, 2023*, pp. 28492-28518.

الفكرة: نموذج تعرّف على الكلام من OpenAI تدريب على 680 ألف ساعة صوت من الإنترنت بإشراف ضعيف، ويشغل على لغات ولهجات كثيرة بدون تدريب إضافي.

العيوب: أدائه يختلف حسب اللغة واللهجة. ممكن يهلوس كلمات في الصوت غير الواضح. وما تدريب خصيصاً على المصطلحات الطبية، فممكن يغلط فيها حتى لو النطق صحيح.

وش تفيدنا: نستخدمه لتقييم الصوت: نحول الصوت اللي ولّده SpeechT5 لنص ونقارنه بالملخص الأصلي عبر WER. فلازم نذكره ونوضح إن جزء من الأخطاء ممكن يكون من Whisper نفسه مو من SpeechT5.

مكانها في الورقة: Methodology (تقييم الصوت) + Limitations.